ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

KHOA HỆ THỐNG THÔNG TIN

ĐỀ CƯƠNG KHÓA LUẬN TỐT NGHIỆP

Tên đề tài:

NGHIÊN CỨU PHƯƠNG PHÁP HỌC SÂU KẾT HỢP THÔNG TIN TRÌNH TỰ VÀ ĐẶC TRƯNG SINH HỌC CHO DỰ ĐOÁN KHẢ NĂNG CẮT NGOÀI MỤC TIÊU CỦA CRISPR-Cas9

NHÓM SINH VIÊN THỰC HIỆN:

1. Nguyễn Ngọc Hân **MSSV: 23520432**
2. Nguyễn Ngọc Duy Bảo **MSSV: 23520124**

Thành phố Hồ Chí Minh, ngày 11 tháng 09 năm 2026

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

KHOA HỆ THỐNG THÔNG TIN

ĐỀ CƯƠNG KHÓA LUẬN TỐT NGHIỆP

Tên đề tài:

NGHIÊN CỨU PHƯƠNG PHÁP HỌC SÂU KẾT HỢP THÔNG TIN TRÌNH TỰ VÀ ĐẶC TRƯNG SINH HỌC CHO DỰ ĐOÁN KHẢ NĂNG CẮT NGOÀI MỤC TIÊU CỦA CRISPR-Cas9

NHÓM SINH VIÊN THỰC HIỆN:

1. Nguyễn Ngọc Hân **MSSV: 23520432**
2. Nguyễn Ngọc Duy Bảo **MSSV: 23520124**

Thành phố Hồ Chí Minh, ngày 11 tháng 09 năm 2026

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC
CÔNG NGHỆ THÔNG TIN

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM
Độc lập - Tự do - Hạnh phúc

ĐỀ CƯƠNG CHI TIẾT

TÊN ĐỀ TÀI: NGHIÊN CỨU PHƯƠNG PHÁP HỌC SÂU KẾT HỢP THÔNG TIN TRÌNH TỰ VÀ ĐẶC TRƯNG SINH HỌC CHO DỰ ĐOÁN KHẢ NĂNG CẮT NGOÀI MỤC TIÊU CỦA CRISPR-Cas9

TÊN TIẾNG ANH: A DEEP LEARNING APPROACH INTEGRATING SEQUENCE INFORMATION AND BIOLOGICAL FEATURES FOR CRISPR-CAS9 OFF-TARGET CLEAVAGE PREDICTION

Cán bộ hướng dẫn: ThS. Dương Phi Long - Giảng viên Khoa Hệ thống Thông tin, Trường Đại học Công nghệ Thông tin, ĐHQG-HCM.

Thời gian thực hiện: Từ ngày 08/09/2026 đến ngày 27/12/2026

Sinh viên thực hiện:

Nguyễn Ngọc Hân - 23520432

Nguyễn Ngọc Duy Bảo - 23520124

Nội dung đề tài

Mô tả chi tiết mục tiêu

Hệ thống chỉnh sửa gen CRISPR-Cas9 sở hữu tiềm năng to lớn trong y sinh và trị liệu tế bào. Tuy nhiên, phức hợp Cas9-sgRNA vẫn có khả năng nhận diện và phân cắt tại các vị trí ngoài mục tiêu (off-target) trên hệ gen có mức độ tương đồng trình tự cao, tiềm ẩn nguy cơ đột biến nguy hiểm. Trong thực nghiệm tế bào sống, các vị trí ngoài mục tiêu thực sự bị phân cắt chiếm tỷ lệ cực kỳ hiếm trên nền hàng trăm nghìn chuỗi DNA không phân cắt,

dẫn tới sự mất cân bằng phân phối cực hạn. Khóa luận kế thừa kiến trúc tuần tự *Crispr-SGRU* làm nền tảng, đồng thời phát triển một quy trình học sâu cải tiến kết hợp biểu diễn ma trận trình tự với vector đặc trưng sinh học phân tử tường minh nhằm nâng cao độ tin cậy của mô hình trên các bộ dữ liệu mất cân bằng cực hạn.

Mục tiêu cụ thể:

• Chuẩn hóa và mã hóa các cặp trình tự sgRNA-DNA trên các bộ dữ liệu chuẩn của Crispr-SGRU [1], bảo toàn thông tin về đột biến sai khớp và đột biến chèn/xóa đoạn theo hướng bắt cặp phân tử.

• Xây dựng kiến trúc học sâu lai đa nhánh: kết hợp nhánh trích xuất đặc trưng trình tự với nhánh tiếp nhận vector đặc trưng sinh học tường minh, kết thúc bằng một nút sigmoid đơn tạo điểm dự đoán.

• Khảo sát và ứng dụng hàm mất mát kết hợp BCE-Dice cùng cơ chế lấy mẫu phân tầng sinh học, nhằm khảo sát khả năng giảm ảnh hưởng của mất cân bằng lớp và ổn định quá trình huấn luyện đối với lớp thiểu số trên các tập dữ liệu mất cân bằng cực hạn.

• Thực hiện đánh giá hiệu năng mô hình thông qua giá trị trung bình (mean) và độ lệch chuẩn (std) của năm mô hình đơn lẻ. Đối chiếu các thước đo PR-AUC, AUROC, F1, Precision, Recall và MCC với kết quả bài báo gốc, đồng thời làm rõ các khác biệt trong thiết lập thực nghiệm.

• Phân tích sai số chi tiết theo từng bộ dữ liệu và theo các đặc tính sai khớp sinh học để lượng hóa mức độ đóng góp của từng module cải tiến.

Phạm vi và đối tượng

Phạm vi dự án: Nghiên cứu được thực hiện bằng phương pháp tính toán trên các bộ dữ liệu giải trình tự công khai, tập trung vào bài toán phân loại nhị phân. Về quy trình thực nghiệm, 15% tổng số mẫu được trích xuất độc lập ngay từ đầu làm tập kiểm thử mù nhằm bảo toàn tỷ lệ phân phối tự nhiên, 85% dữ liệu còn lại được phân chia phân tầng thành 5 phần (5-Fold) để huấn luyện mô hình, tinh chỉnh siêu tham số và xác định ngưỡng phân loại tối ưu. Đánh giá cuối cùng được thực hiện trên cùng một tập kiểm thử cố định này để bảo đảm tính khách quan và nhất quán giữa các biến thể mô hình.

Đối tượng nghiên cứu: Các cặp trình tự sgRNA-DNA dài 23-24 nucleotide đã qua căn chỉnh cục bộ kèm nhãn nhị phân ghi nhận hoạt tính cắt ngoài mục tiêu. Đầu vào mô hình gồm ma trận 24 × 7 mã hóa 4 kênh nucleotide, 1 kênh khoảng trống indel và 2 kênh biểu

thị hướng đột biến, kế thừa cách biểu diễn từ các công trình nền tảng [1] [2]. Các đặc trưng sinh học dự kiến khảo sát gồm loại, số lượng và vị trí sai khớp tương đối so với PAM, phân bố sai khớp ở vùng gần và xa PAM, cùng chênh lệch hàm lượng GC giữa hai chuỗi. Tập đặc trưng cuối cùng được lựa chọn và kiểm chứng bằng thực nghiệm.

Dataset: Nghiên cứu khảo sát 8 bộ dữ liệu thực nghiệm tiêu chuẩn gồm CHANGE-seq, I1, K562, HEK293t, BE3, II5, I2 và II6 [1]. Về hình thái đột biến, I1 và I2 ghi nhận đồng thời cả đột biến sai khớp (mismatch) và chèn/mất đoạn (indel); 6 bộ dữ liệu còn lại chỉ chứa đột biến sai khớp nucleotide thuần túy. Về điều kiện thực nghiệm, CHANGE-seq là dữ liệu giải trình tự trong ống nghiệm (*in vitro*) quy mô lớn với tỷ lệ mất cân bằng thấp nhất trong các bộ dữ liệu; 7 bộ dữ liệu còn lại có dải tỷ lệ mất cân bằng (IR) trải rộng, từ mức vừa phải như HEK293t, K562 đến các tập có mức độ mất cân bằng cực hạn và số lượng mẫu dương rất ít như BE3, II5, I2 và II6.

Phương pháp thực hiện:

Nội dung 1: Tiền xử lý và biểu diễn dữ liệu

Chuẩn hóa chuỗi và mã hóa cặp sgRNA-DNA thành ma trận nhị phân 24×7 đại diện cho nucleotide, khoảng trống indel và hướng đột biến. Song song đó, xây dựng module trích xuất vector đặc trưng sinh học tường minh. Cố định 15% dữ liệu làm tập kiểm thử độc lập nhằm bảo đảm tính nhất quán khi đối chuẩn giữa các mô hình.

Nội dung 2: Xây dựng kiến trúc mô hình học sâu lai

Thiết kế mạng hai nhánh tích hợp: nhánh chuỗi kế thừa từ Crispr-SGRU [1] và nhánh tiếp nhận vector đặc trưng sinh học. Hai luồng thông tin được tích hợp tại tầng hợp nhất đặc trưng, sau đó đi qua các lớp Dense thu hẹp, lớp Dropout để giảm quá khớp và kết thúc bằng một nút sigmoid đơn để tạo điểm dự đoán cho lớp có ghi nhận hoạt tính ngoài mục tiêu.

Nội dung 3: Chiến lược huấn luyện và lấy mẫu phân tầng sinh học

Mỗi mô hình trong 5-fold được tối ưu bằng thuật toán Adam, ứng dụng hàm mất mát kết hợp BCE-Dice nhằm ổn định gradient và tối ưu vùng chồng lấn lớp dương tính. Bộ sinh dữ liệu áp dụng cơ chế phân tầng trong từng batch. Mô hình được lưu checkpoint theo validation loss tối ưu kết hợp bộ giảm tốc độ học tự động ReduceLROnPlateau.

Nội dung 4: Lựa chọn ngưỡng phân loại, đánh giá và đối chuẩn

Quét tìm ngưỡng phân loại tối ưu trên tập xác thực dựa trên chỉ số MCC và F_1-score [3]

trước khi áp dụng đánh giá trên tập kiểm thử độc lập 15%. Báo cáo kết quả dưới dạng mean ± std qua 5 mô hình đơn lẻ theo các thước đo: PR-AUC, AUROC, F1, Precision, Recall và MCC. Cuối cùng, đối chiếu kết quả với số liệu công bố của Crispr-SGRU [1] và thực hiện phân tích sai số theo nhóm đột biến để lượng hóa đóng góp thực tế của từng module cải tiến.

Kết quả mong đợi

Đề tài kỳ vọng xây dựng được một quy trình thực nghiệm học sâu hoàn chỉnh, có cấu hình chuẩn hóa và mã nguồn có tính tái lập cao. Cải thiện được độ ổn định của các chỉ số PR-AUC, F1 và MCC trên các bộ dữ liệu mất cân bằng cực hạn (II6, I2, II5, BE3). Làm rõ vai trò, ưu điểm và hạn chế của việc kết hợp vector đặc trưng sinh học tường minh so với mô hình chuỗi thuần túy để đánh giá khả năng cải thiện hiệu năng dự đoán và xác định giới hạn áp dụng.

Tài liệu tham khảo

[1] Zhang, G.; Luo, Y.; Xie, H.; Dai, Z. (2024). Crispr-SGRU: Prediction of CRISPR/Cas9 Off-Target Activities with Mismatches and Indels Using Stacked BiGRU. International Journal of Molecular Sciences, 25, 10945. DOI: 10.3390/ijms252010945.

[2] Lin, J.; Zhang, Z.; Zhang, S.; Chen, J.; Wong, K. C. (2020). CRISPR-Net: A Recurrent Convolutional Network Quantifies CRISPR Off-Target Activities with Mismatches and Indels. Advanced Science, 7, 1903562.

[3] Lipton, Z. C.; Elkan, C.; Narayanaswamy, B. (2014). Thresholding Classifiers to Maximize F1 Score. arXiv:1402.1892.

Kế hoạch thực hiện

Thời gian	**Công việc**	**Phân công**
Tuần 1-2	Rà soát bài báo Crispr-SGRU, xác định bài toán, khảo sát các đặc trưng sinh học cần nhúng và cấu trúc 8 bộ dữ liệu chuẩn.	Bảo, Hân
	Kiểm tra dữ liệu, xây dựng module mã hóa ma trận	

Tuần 3-4	24 × 7, trích xuất vector đặc trưng sinh học (Seed, PAM, GC) và hoàn thiện bộ chia 5-fold cố định.	Bảo, Hân
Tuần 5-7	Thực nghiệm pipeline học sâu nền tảng với hàm mất mát BCE-Dice và bộ lấy mẫu phân tầng sinh học. Ghi nhận chỉ số và phân tích sai số trên các bộ dữ liệu.	Bảo, Hân
Tuần 8-10	Tích hợp nhánh đặc trưng sinh học vào mô hình. Tiến hành các thí nghiệm bóc tách đối chứng với mô hình thuần chuỗi.	Bảo, Hân
Tuần 11-13	Tổng hợp bảng kết quả mean ± std, đối chiếu đa chiều với số liệu bài báo, phân tích giới hạn sinh học và hoàn thiện bản thảo khóa luận.	Bảo, Hân
Tuần 14 trở đi	Rà soát theo góp ý của cán bộ hướng dẫn và hoàn thiện bản nộp.	Bảo, Hân

Xác nhận của CBHD (Ký tên và ghi rõ họ tên)	**TP. HCM, ngày 11 tháng 09 năm 2026** **Sinh viên** (Ký tên và ghi rõ họ tên)